



AKADEMIA GÓRNICZO-HUTNICZA  
IM. STANISŁAWA STASZICA W KRAKOWIE

# Przetwarzanie Języka Naturalnego

## Lab 1

Zbigniew Kaleta  
[zkaleta@agh.edu.pl](mailto:zkaleta@agh.edu.pl)

Wydział IEiT  
Katedra Informatyki

8.03.2019

- ✚ tryb laboratoryjny
- ✚ 1.5 h tygodniowo do końca semestru
- ✚ obecność obowiązkowa
- ✚ konsultacje: czwartek 10:30 – 11:30 lub po umówieniu mailowo w 4.60

## Zaliczenie (I opcja)

- ✦ 10 zestawów zadań domowych, za każdy do zdobycia maks. 3 pkt.
- ✦ kolokwium za 10 pkt. na koniec semestru
- ✦ w przypadku usprawiedliwionej nieobecności zadania należy oddać na pierwszych zajęciach, z których się nie ma zwolnienia
- ✦ **zadania z danego laboratorium należy oddać na następnych zajęciach**
- ✦ **każdy tydzień spóźnienia oznacza utratę 1 pkt. z danego zadania (bez punktów ujemnych)**

## Zaliczenie (II opcja)

- ✦ 10 zestawów zadań domowych, za każdy do zdobycia maks. 3 pkt.
- ✦ kolokwium za 10 pkt. na koniec semestru
- ✦ w przypadku usprawiedliwionej nieobecności zadania należy oddać na pierwszych zajęciach, z których się nie ma zwolnienia
- ✦ **zadania z danego laboratorium należy oddać na jednym z dwóch następnych zajęć**
- ✦ **na koniec semestru można poprawić jedno dowolne zadanie**

- ✚ n-gramem nazywamy **każdą** sekwencję n kolejnych składowych
- ✚ sekwencje mogą się zazębiać
- ✚ w przypadku analizy języka składowymi mogą być litery, sylaby lub słowa

Ala ma kota,  $n = 2$

Słowo: przetwarzanie

digramy: pr, rz, ze, et, tw, wa, ar, rz, za, an, ni, ie

trigramy: prz, rze, zet, etw, twa, war, arz, rza, zan, ani, nie

Zdanie: Mężny bądź, chroń pułk twój i sześć flag.

digramy: Mężny bądź, bądź chroń, chroń pułk, pułk twój, twój i, i sześć, sześć flag

- ✦ pozwala przedstawić korpus tekstowy w postaci wektora częstości ngramów
- ✦ prosty
- ✦ skalowalny (ze względu na wielkość korpusu czy  $n$ ?)

jest to po prostu w  
sklearn CountVectorizer

# Odległość między wektorami

Albo może tutaj ma

$$x = [x_1, x_2, \dots, x_n]$$

$$y = [y_1, y_2, \dots, y_n]$$

może  $421 \cdot 2 + 100 \cdot 1 + 2 \cdot 1$

✦ euklidesowa:  $d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$

✦ taksówkowa:  $d(x, y) = |x_1 - y_1| + |x_2 - y_2| + \dots + |x_n - y_n|$

✦ maksimum:  $d(x, y) = \max(|x_1 - y_1|, |x_2 - y_2|, \dots, |x_n - y_n|)$

✦ cosinusowa:  $d(x, y) = 1 - \frac{x_1 * y_1 + x_2 * y_2 + \dots + x_n * y_n}{\text{len}(x) * \text{len}(y)}$

Normalizacja?

Normy nie będąc wektorem!





AGH

## Miary poprawności klasyfikacji (binarnej)

- ✚ Precision (precyzja): jak duży procent obiektów zaklasyfikowanych do A został poprawnie zaklasyfikowany

$$precision = \frac{|true\ positives|}{|true\ positives \cup false\ positives|}$$

- ✚ Recall (pełność): jak duży jest procent poprawnie zaklasyfikowanych obiektów względem wszystkich obiektów w zbiorze wzorcowym

$$recall = \frac{|true\ positives|}{|true\ positives \cup false\ negatives|}$$

- ✚ F1: średnia harmoniczna miar precision i recall

$$F_1 = 2 \cdot \frac{precision \cdot recall}{precision + recall}$$

- ✚ Accuracy (skuteczność):

$$accuracy = \frac{|true\ positives \cup true\ negatives|}{|true\ positives \cup false\ positives \cup true\ negatives \cup false\ negatives|}$$

to bi  
weine  
szerepokie

- 1 Napisać program budujący statystykę n-gramów dla różnych języków (1 pkt.)
- 2 Napisać program odgadyujący język zdania wprowadzonego przez użytkownika (1 pkt.)
- 3 Przeanalizować wyniki odgadywania w zależności od  $n$ , obliczyć miary poprawności (1 pkt.)

Korpusy:

<http://home.agh.edu.pl/~zkaleta/pjn/lab1.tar.gz>